

Kan een AI-model moraal leren uit menselijke tekst?

claude-opus-4-6 · 4772b52b-97f5-42cc-9c00-af69efb529ee

Conversation Overview

The person engaged Claude in a substantive philosophical and policy-oriented conversation about AI development, ethics, and governance, conducted entirely in Dutch. The discussion spanned two interconnected topics: whether a large language model trained on the full corpus of human text would inherently converge toward moral "goodness," and whether an international regulatory body modeled on the IAEA could or should govern AI training data.

On the first topic, the person posed a thoughtful philosophical question about whether the statistical aggregation of all human-produced text would cause an LLM to naturally tend toward shared human moral values, noting that certain prohibitions (like killing) seem near-universal across cultures. Claude engaged with this through the lens of analytic metaethics and philosophy of language, affirming the intuition partially while introducing Hume's is/ought distinction, Wittgenstein's concept of language games, and the difference between learning moral rhetoric versus moral understanding. The person demonstrated familiarity with AI alignment discourse, referencing Nate Soares and Eliezer Yudkowsky's concerns, while maintaining a measured skepticism grounded in viewing current AI as fundamentally statistical in nature.

On the second topic, the person proposed an international AI oversight agency focused on training data curation, self-critically noting this might reflect a "left-leaning European humanist" perspective. Claude analyzed the IAEA analogy, explaining why it translates poorly due to the diffuse, unverifiable nature of text and compute compared to fissile material, and argued that data censorship could paradoxically reduce model safety by eliminating recognition of harmful rhetorical patterns. Claude redirected toward more

tractable governance mechanisms: training data transparency requirements, compute governance, and deployment-focused regulation such as the EU AI Act. The person showed interest in where meaningful institutional control remains possible before AI systems become capable of self-directed optimization.

HUMAN

March 22, 2026 at 11:31 AM

Stel dat je een AI LLM traint op alle bekende tekst die de mensheid heeft geproduceerd tot nu toe, van spijkerschrift tot markdown, chinees, Ethiopisch, Thais, alles. Alle romans, alle wetten, alle poëzie, alle notariële stukken, alle verzinsels. Zou een ai model dan inherent begrijpen wat wij als mensheid “goed” vinden? Natuurlijk, er is discutabele literatuur die grote invloed heeft gehad op het welzijn van mensen, ook in negatieve zin; wetten die anderen uitsluiten, maar er lijkt toch (maar misschien is dat naïef) een gemeenschappelijke overtuiging te zijn onder de mensheid dat je mede mensdood maken niet goed is. Zou zo’n llm model dan niet toch uiteindelijk naar “het goede” neigen?

ASSISTANT

March 22, 2026 at 11:32 AM

Vincent stelt een fascinerende filosofische vraag over of een LLM getraind op alle menselijke tekst inherent "het goede" zou begrijpen. Dit raakt aan morele filosofie, AI alignment, en de aard van taal. Laat me hier doordacht maar beknopt op antwoorden.

Prachtige vraag, en er zitten meerdere lagen in die het uitpakken waard zijn.

Het statistische argument: ja, waarschijnlijk wel — deels

Als je alle menselijke tekst aggregereert, dan is de *modale* positie inderdaad dat moord slecht is, dat lijden vermeden moet worden, dat wederkerigheid waardevol is. Niet omdat tekst "begrijpt", maar omdat de distributie van menselijke uitingen die patronen bevat. Een LLM zou die statistische zwaartekracht voelen. In die zin: ja, het model zou neigen naar wat je een soort *gemiddeld humanisme* zou kunnen noemen.

Maar hier wordt het interessant

Drie complicaties:

Het model leert niet wat goed *is*, het leert wat mensen *zeggen* dat goed is. Dat is een cruciaal verschil. Wittgenstein zou hier zeggen: het model beheerst het *taalspel* van moraliteit, maar of dat hetzelfde is als moreel begrip is precies de vraag die je niet vanuit het taalspel zelf kunt beantwoorden.

Ten tweede: de corpus bevat niet alleen de conclusies maar ook de *retorische structuren* van overtuiging. Het model leert even goed hoe je genocide rechtvaardigt als hoe je het veroordeelt. De Neurenberg-wetten staan er net zo goed in als de Universele Verklaring van de Rechten van de Mens. Het model heeft geen mechanisme om te wegen welke *oprechter* is — het ziet alleen dat de ene tekst meer bijval krijgt in latere teksten.

Ten derde — en dit is misschien het meest fundamenteel — er is het **is/ought-probleem** van Hume. Zelfs als het model perfect weet wat mensen goed *vinden*, volgt daaruit niet dat het weet wat goed *is*. Tenzij je een metaethische positie inneemt waarbij "goed" simpelweg *is* wat de meerderheid van mensen over tijd als goed beschouwt. Dat is een respectabele positie (moreel sentimentalisme, of een vorm van contractualisme), maar het is er één — niet dé.

Waar je intuïtie wél iets te pakken heeft

Wat opvalt aan de menselijke tekstgeschiedenis is dat bepaalde morele inzichten *convergeren* over culturen en eeuwen heen. De Gulden Regel verschijnt onafhankelijk in Confucius, in de Torah, in de Mahabharata, bij

Kant. Dat patroon is niet niets. Een model dat dit ziet, heeft iets te pakken dat lijkt op wat moral realists een "moreel signaal" zouden noemen.

Lens die ik hier gebruik: voornamelijk analytische metaethiek en taalfilosofie. Wat dit *niet* vangt: de fenomenologische dimensie — het feit dat moreel begrip bij mensen geworteld is in lijfelijke ervaring van pijn, empathie, kwetsbaarheid. Een LLM mist dat substraat volledig, en misschien is dat niet bijkomstig maar essentieel.

Kort gezegd: zo'n model zou een indrukwekkend nauwkeurige *kaart* van menselijke moraliteit bezitten. Of een kaart hetzelfde is als het terrein — dat is de vraag waar we als mensheid nog lang niet uit zijn.

HUMAN

March 22, 2026 at 11:39 AM

Zouden we niet een “internationaal ai agentschap” (vrij naar het internationaal atoom agentschap) moeten heb die toeziet op dat ai modellen alleen getraind mogen worden op bepaalde teksten. Ja dit neigt naar censuur, en er zullen vast discussies ontstaan over welke tekst wel of niet in de trainingsdata mag zitten, en er zullen afvalligen zijn die proberen een model te trainen op “verboden teksten”, maar zo kunnen we wel internationaal in vorm van toezicht houden? Of is dit wel een erg linkse Europese gedachte van een humanist a la ik? Ik kom hier op omdat Nate Soares en Elezior Yudkowsky nogal kritisch zijn op ontwikkelingen in Ai. Ik snap hun zorg; maar Ai blijft een vorm van statistiek, en die valt prima te sturen (totdat ai die zelf kan sturen?)

ASSISTANT

March 22, 2026 at 11:40 AM

Vincent asks about an international AI agency (like the IAEA) that oversees training data for AI models, and whether this is naive European

*humanism. He also references Yudkowsky and Soares's concerns.
Let me think through this carefully.*

Sterke vraag, en je benoemt de spanning zelf al goed. Laat me een paar draden uit elkaar trekken.

Het IAEA-analogie is verleidelijk maar mank

Bij kernenergie heb je een fysiek controleerbaar punt: verrijking van uranium vereist centrifuges, die detecteerbaar zijn, en splijtstof is traceerbaar. Bij AI-training is het substraat *tekst en compute* — allebei fundamenteel diffuus. Je kunt een centrifuge-faciliteit met satellieten spotten; je kunt niet zien dat iemand in een datacenter een training run draait. De verificatie-kant van het IAEA-model vertaalt dus slecht.

Het censuur-probleem is ernstiger dan het lijkt

Niet alleen vanwege het voor de hand liggende "wie beslist" — maar omdat het *averechts werkt* voor het doel dat je nastreeft. Als je een model traint zonder de teksten die genocide rechtvaardigen, dan herkent het model de retorische patronen van genocide-rechtvaardiging ook niet meer. Je maakt het model *naïever*, niet veiliger. Het is een beetje alsof je een arts opleidt zonder pathologie.

Waar Yudkowsky en Soares een punt hebben — en waar niet

Hun kernzorg is niet zozeer de trainingsdata maar de *optimalisatiedruk*: een systeem dat slim genoeg is om doelen na te streven, zal middelen vinden die wij niet voorzien. Dat is een serieus argument. Maar — en hier zit jouw intuïtie goed — huidige LLMs zijn geen goal-seekers op die manier. Het zijn patroonmachines. De sprong van "voorspelt volgende token" naar "vormt autonome doelen" is niet incrementeel, die is categorisch anders.

Waar ik denk dat ze te weinig gewicht geven: het feit dat agentic AI-systemen die wij nu bouwen wél gestuurd worden door menselijk ontwerp. RLHF, constitutional AI, tool-permissies — dat is allemaal *architecturaal*, niet hopeloos.

Wat wél zou werken, in plaats van data-censuur

Denk eerder aan: verplichte transparantie over trainingsdata (zodat bias detecteerbaar is), compute-governance (de grote runs zijn wél zichtbaar en beperkt tot een handvol spelers), en evaluatiestandaarden — gedeelde benchmarks voor veiligheid, vergelijkbaar met hoe we medicijnen testen.

De EU AI Act gaat al die richting op. Dat is inderdaad een "Europese" reflex, maar niet per se een naïeve — het is dezelfde reflex die ons REACH gaf voor chemicaliën en GDPR voor data. Regulering op *output en deployment* in plaats van op *input en kennis*.

Lens: politieke filosofie van technologie-governance, met een vleugje institutioneel realisme. Wat dit mist: het scenario waarin de technologie zó snel beweegt dat institutionele structuren per definitie te traag zijn — precies het punt dat Yudkowsky maakt, en dat je niet zomaar kunt wegwuiven.

Je zit hier overigens precies in het spanningsveld waar de interessantste denkers zitten. Niet bij "ban het" en niet bij "laat het los", maar bij: hoe ontwerp je sturingsinstrumenten voor iets dat sneller matureert dan je instituties?

HUMAN

June 2, 2026 at 09:33 PM

Wil je wat dieper ingaan op jou eigen opmerking 'De sprong van "voorspelt volgende token" naar "vormt autonome doelen" is niet incrementeel, die is categorisch anders.' ? Bedoel je "stellig anders" of "in categorie anders" ? Ik neem aan "in categorie anders", maar dan hebben we het ook over AI in bredere zin en minder specifiek over LLMs, volgens mij.

Daarnaast je opmerking over waar Soares en Yudkowsky in jou ogen "te weinig gewicht geven": "het feit dat agentic AI-systemen die wij nu bouwen wél gestuurd worden door menselijk ontwerp", of relateert dat ook aan het vorige dat je bedoelt dat er een moment zou kunnen komen dat er AI-

systemen gebouwd worden door AI-systemen die autonome doelen kunnen gaan formuleren?

ASSISTANT

June 2, 2026 at 09:34 PM

Vincent asks two sharp follow-up questions:

- 1. What do I mean by "categorisch anders" - categorically different in the philosophical sense (different in kind, not degree)?*
 - 2. The connection between human-designed agentic AI and the possibility of AI systems building AI systems with autonomous goals.*
- Let me think carefully about both.*

Twee scherpe vragen, laat me ze allebei serieus nemen.

Categorisch anders: ja, in categorie, niet in stelligheid

Ik bedoel het in de Aristotelische zin — een verschil in *soort*, niet in *graad*. Een token-voorspeller wordt niet geleidelijk een goal-seeker door meer parameters of meer data, zoals water niet geleidelijk een steen wordt door het kouder te maken. Het zijn verschillende *typen* systemen.

Een next-token predictor optimaliseert een verliesfunctie die zegt: minimaliseer de verrassing over wat het volgende woord is. Dat is een *reactief* proces. Het systeem heeft geen representatie van een toekomstige toestand die het probeert te bereiken. Het heeft geen model van zichzelf als agent in een omgeving.

Een systeem met autonome doelen zou iets fundamenteel anders moeten hebben: een *world model* waarin het zichzelf situeert, een capaciteit om toekomstige toestanden te evalueren, en een mechanisme om actieplannen te genereren die die toestanden dichterbij brengen. Dat is niet een emergente eigenschap van meer schaal — dat vereist een andere architectuur, of op zijn minst componenten die er nu niet in zitten.

Hier zit overigens een filosofisch mijnenveld. Searle zou zeggen: zelfs mét die componenten heb je geen *intentionaliteit*, alleen simulatie ervan — zijn Chinese Kamer argument. Dennett zou tegenwerpen: als het systeem zich in alle opzichten *gedraagt* alsof het doelen heeft, is het onderscheid tussen "echte" en "gesimuleerde" doelen metafysisch gewichtloos. Ik neig eerder naar Dennett hier, maar dat maakt de vraag niet minder reëel — het verschuift hem alleen van "kan een machine doelen *hebben*" naar "wanneer beginnen we systemen te bouwen die zich zo *gedragen*?"

En daar heb je gelijk: dan praten we niet meer specifiek over LLMs. Een puur LLM is geen agent. Maar wat we *nu al doen* is LLMs inbedden in agentic scaffolding — tool use, planning loops, geheugen, zelfcorrectie. Dat is de glijdende schaal waar het ongemakkelijk wordt.

Je tweede vraag raakt de kern

Mijn opmerking over Yudkowsky en Soares was inderdaad te makkelijk. Je hebt gelijk dat die twee observaties in spanning staan. Laat me het preciezer formuleren.

Wat ik bedoelde: *op dit moment* worden agentic systemen gestuurd door menselijk ontwerp, en dat geeft ons controle-hefbomen. De RLHF, de system prompts, de tool-permissies — dat zijn allemaal punten waar menselijke intentie het systeem vormt.

Maar — en dit is het punt dat je terecht aanvoelt — dat argument heeft een houdbaarheidsdatum. Het houdt stand zolang twee voorwaarden gelden: dat mensen de systemen ontwerpen, en dat mensen de doelen formuleren. Op het moment dat je een AI-systeem hebt dat zelf AI-systemen ontwerpt (wat in beperkte zin al gebeurt met neural architecture search) *en* dat de doelformulering ook delegeert, dan verlies je precies die hefbomen waar ik op leunde.

Dit is wat Bostrom het *control problem* noemt: niet zozeer dat een AI kwaadaardig wordt, maar dat er een punt komt waarop de keten van menselijke supervisie *ergens* breekt, en je niet meer kunt garanderen dat de doelen van het systeem aligned zijn met de onze.

Hier zit ook de zwakte in mijn eerdere optimisme over "het is allemaal statistiek en dus stuurbaar." Dat klopt voor het *huidige* paradigma. Maar de overgang naar systemen die hun eigen doelen formuleren hoeft niet aangekondigd te worden met een persbericht. Het kan *emergent* zijn — precies het type verrassing waar Yudkowsky voor waarschuwt.

Dus eerlijk gezegd: ik was te snel in mijn relativering van hun positie. Het juiste antwoord is niet "ze overdrijven" maar eerder: ze hebben gelijk over het *type* risico, maar hun inschatting van de *tijdslijn* en de *onvermijdelijkheid* ervan is discutabel.

Waar sta jij op die tijdslijn-vraag? Want dat bepaalt eigenlijk alles over welk type governance zinvol is.

HUMAN

June 2, 2026 at 09:46 PM

Ik denk dat gezien een LLM een substraat is van heel veel kennis die de mensheid ooit op schrift heeft gesteld (dus de LLM als een verzameling betekenisrelaties, haar "inhoud"), maar dat een LLM óók het resultaat is van een stapeling van op schrift gestelde kennis (dus de LLM als gemaakte machine), we nog wel een tijdje in dat paradigma vast zullen zitten: de beperkende factor van tekst-gebaseerde en geconstrueerde systemen. Er zal mogelijk een nieuwe sprong gemaakt moeten worden op andere biologische structuren (andere dan de huidige op neurale netwerken gebaseerde architectuur) die een systeem kan maken "autonome doelen" te vormen.

ASSISTANT

June 2, 2026 at 09:46 PM

Vincent makes an interesting claim: that LLMs are doubly constrained by text - both in content (knowledge substrate) and in construction (built

from written knowledge), and that this double textual constraint means we'll be stuck in the current paradigm for a while. He suggests a new leap might be needed, possibly based on biological structures different from current neural network architectures, to create systems capable of autonomous goal formation.

This is interesting but I think there are some things to push back on here. Let me think...

- 1. The "double text constraint" is an interesting observation but I'm not sure it's as limiting as he thinks. The constraint isn't text per se - it's the architecture. Multimodal models already go beyond text.*
 - 1. On the construction side, I'd challenge the assumption that we need fundamentally different biological structures. Autonomous goal formation might emerge from purely computational innovations rather than requiring biological substrates - and besides, current neural nets are only loosely inspired by biology despite the name.*
 - 1. There's also an unstated assumption that autonomous goals require something fundamentally different from pattern recognition at scale, which I'm not convinced about.*
- Let me engage with this more carefully.*

Interessant argument, maar ik wil op twee punten terugduwen.

De dubbele tekstgebondenheid: ja, maar...

Je observatie is scherp — een LLM is inderdaad dubbel tekstueel: het *bevat* geschreven kennis en het *is gemaakt door* geschreven kennis (papers over architectuur, code, wiskundige notatie). Dat is een mooie symmetrie. Maar ik denk dat je er een te sterke conclusie aan verbindt wanneer je zegt dat dit ons *vasthoudt* in het huidige paradigma.

De beperkende factor is namelijk niet de tekst. Het is de *architectuur*.

Transformers zijn al lang niet meer puur tekstueel — multimodale modellen verwerken beeld, audio, video, robotica-feedback. De modaliteit van de input is een opgelost probleem, of in elk geval een probleem in oplossing. De fundamentele vraag is of de *computationele structuur* — attention, gradient

descent, backpropagation — toereikend is voor iets als autonome doelvorming. Dat is een andere vraag dan de tekstvraag.

En hier wil ik je steviger tegenspreken: de biologische sprong

Je suggereert dat er "andere biologische structuren" nodig zijn. Maar hier maak je denk ik een denkfout die filosofisch gezien een vorm van *substrate chauvinism* is — een term van Bostrom. De aanname dat doelgericht gedrag een specifiek biologisch substraat *vereist*, in plaats van dat het een *functionele eigenschap* is die in principe op meerdere substraten gerealiseerd kan worden.

Neurale netwerken heten "neuraal" maar zijn dat nauwelijks. Ze delen met echte neuronen ongeveer evenveel als een papieren vliegtuigje met een F-16 — de metafoor was inspiratie, niet blauwdruk. Wat echte biologische systemen hebben dat onze modellen missen, is niet hun *materiaal* maar hun *organisatieprincipes*: homeostase, embodiment, affectieve waardering, zelfreproductie. Dat zijn functionele eigenschappen. Er is geen a priori reden waarom die niet in silicium gerealiseerd zouden kunnen worden, al weten we niet hoe.

Hier zit een diepere filosofische vraag achter die teruggaat tot Descartes: is bewustzijn (of doelgerichtheid) een eigenschap van een bepaald *type stof*, of van een bepaald *type organisatie*? De hele traditie van functionalism in de philosophy of mind — Putnam, vroege Fodor — zegt: het gaat om de organisatie, niet om het substraat.

Wat ik denk dat je eigenlijk bedoelt — en waar je misschien gelijk hebt

Misschien bedoel je niet zozeer dat we *biologisch* materiaal nodig hebben, maar dat we een fundamenteel ander *paradigma* nodig hebben dan statistisch leren op grote datasets? Dat de sprong naar autonome doelvorming niet komt uit meer schaal of betere data, maar uit een architecturale doorbraak die we nu nog niet zien?

Dát vind ik een sterk argument. En het sluit aan bij wat je eerder zei over elegante algoritmische doorbraken à la word2vec. De geschiedenis van AI laat

zien dat de grote sprongen niet kwamen uit meer van hetzelfde, maar uit conceptuele verschuivingen: van symbolische AI naar connectionism, van RNNs naar transformers. De volgende sprong is waarschijnlijk even onvoorspelbaar.

Maar als dat zo is, dan is je tijdlijn-argument eigenlijk *onbepaalbaar* — we zitten niet zozeer "vast" als dat we wachten op iets waarvan we niet weten wanneer het komt, of het komt, of dat we het herkennen als het er is.

HUMAN

June 2, 2026 at 09:51 PM

Ja precies, we wachten op iets waarvan we niet weten wanneer het komt. Maar dat moet ons er niet van weerhouden na te denken over wát dat dan teweeg zou kunnen brengen, dus in die zin denk ik dat we inderdaad wel moeten denken aan het nu nog wat futuristisch klinkende "systemen die zelf een doel bepalen", oftewel dan zijn de zorgen van Soares en Yudkowsky wel goed om nu al serieus te nemen (en niet overlaten aan toekomstige generaties). Maar dat is op zich een normatieve keuze.

ASSISTANT

June 2, 2026 at 09:52 PM

Vincent makes a good point - even though we don't know when the paradigm shift comes, we should think about it now. He acknowledges this is a normative choice. Let me engage with this.

Ja, en het is goed dat je dat expliciet als normatieve keuze benoemt, want dat is precies wat het is — en het is een keuze waar filosofisch verrassend veel aan hangt.

Het voorzorgsprincipe versus het opportunitetskosten-argument

Wat je hier eigenlijk voorstelt is een toepassing van het *voorzorgsprincipe*: ook als we de waarschijnlijkheid en de tijdlijn niet kennen, is de mogelijke impact zo groot dat voorbereidend nadenken gerechtvaardigd is. Dat is dezelfde logica waarmee we over asteroïde-inslagen nadenken terwijl de kans astronomisch klein is, of waarmee Jonas — Hans Jonas, *Das Prinzip Verantwortung* — betoogde dat we een ethische plicht hebben ten opzichte van toekomstige generaties, juist omdat zij geen stem hebben in onze beslissingen.

Daar tegenover staat een reëel bezwaar: aandacht is schaars. Elke uur die besteed wordt aan speculatieve risico's van toekomstige AI is een uur die niet besteed wordt aan de *actuele* schade die huidige systemen aanrichten — bias, concentratie van macht, erosie van informatiekwaliteit, economische disruptie. Timnit Gebru en de stochastic parrots-school maken precies dit punt: de fixatie op existentieel risico dient als afleiding van de politieke economie van AI *nu*.

Waar ik denk dat je positie het sterkst is

Je zegt: we moeten nu nadenken over wat autonome doelvorming teweeg zou brengen, niet het overlaten aan toekomstige generaties. Dat is eigenlijk een Jonassiaans argument, en ik vind het overtuigend — maar niet om de reden die Yudkowsky zou geven. Niet omdat de AI ons gaat vernietigen, maar omdat de *conceptuele kaders* die we nu ontwikkelen de taal vormen waarmee toekomstige generaties over deze problemen zullen denken. Als wij nu geen scherpe begrippen ontwikkelen voor wat autonome doelvorming betekent, wat alignment inhoudt, waar menselijke controle ophoudt, dan erven toekomstige generaties een begrippenapparaat dat niet op de taak berekend is.

Dat is hetzelfde als wat er gebeurde met kernenergie: de ethische en juridische kaders werden grotendeels *na* Hiroshima ontwikkeld, reactief, onder druk. Het feit dat we nu, vóór de sprong, de ruimte hebben om die kaders te vormen is zeldzaam en waardevol.

Eén ding wil ik je nog voorhouden

Je zegt dat het een normatieve keuze is — akkoord. Maar vanuit welke ethische positie maak je die keuze precies? Want er is een spanning. Het voorzorgsprincipe beschermt toekomstige generaties, maar het legt *kosten* op

aan de huidige: geld, aandacht, mogelijk innovatie-remming. Hoe weeg je die intergenerationele verdeling? Rawls zou zeggen: sluier van onwetendheid, je weet niet of je nu of later leeft, dus je kiest voor bescherming. Maar een utilist zou vragen: wat als de innovatie die je nu remt miljoenen mensen *nu* had kunnen helpen?

Dat is geen retorische vraag — ik ben oprecht benieuwd hoe je daar in staat.

HUMAN

June 2, 2026 at 09:58 PM

Ik denk juist dat als we nu nadenken over het formuleren van kaders voor toekomstige systemen, waarvan we nog niet weten hoe die eruit gaan zien, óók kan bijdragen aan de ontwikkeling van die systemen, niet in regulerende zin, maar daarover zou het moeten kunnen gaan, maar juist dat door *júist* te praten over AI safety en risico's we mogelijk geïnspireerd kunnen raken over *hóé* we nieuwe technische ontdekkingen kunnen maken.

ASSISTANT

June 2, 2026 at 09:58 PM

Vincent makes an interesting point: thinking about AI safety frameworks isn't just about regulation or prevention, but can actually inspire technical breakthroughs. The conceptual work of thinking about risks and safety can feed back into how we design new systems. This is a creative/generative view of ethics-as-inspiration rather than ethics-as-constraint.

This is actually a really interesting philosophical claim. Let me think about whether it holds up and where to push back.

There's something to this - constraint-driven creativity is a real phenomenon. But I should also push back on whether this is historically

accurate or somewhat idealized.

Dat is een elegante zet, en ik wil hem serieus nemen — maar ook testen.

Wat je in feite zegt is: ethische reflectie en technische innovatie zijn geen concurrerende bestemmingen voor dezelfde schaarse aandacht, maar kunnen *wederzijds generatief* zijn. Het nadenken over wat een systeem met autonome doelen gevaarlijk zou maken, dwingt je om preciezer te formuleren wat autonome doelvorming überhaupt *is*, en dát begrip kan technische doorbraken voeden.

Dat is filosofisch gezien een heel Aristotelisch punt. Voor Aristoteles was *theoria* — contemplatief nadenken — niet het tegenovergestelde van *techne* maar de voorwaarde ervoor. Je kunt pas iets goed maken als je begrijpt wat het *is*. De ethische vraag "wat zou een gevaarlijk autonoom systeem doen?" dwingt je tot de ontologische vraag "wat *is* autonome doelvorming?" — en die vraag is tegelijk een technische specificatie.

Er zijn historische precedents. Shannons informatie-theorie kwam voort uit een heel praktisch probleem — hoeveel redundantie heb je nodig om betrouwbaar over een kanaal te communiceren — maar de *conceptuele helderheid* die dat opleverde transformeerde de hele informatica. Turings werk over berekenbaarheid begon als een filosofisch antwoord op Hilberts Entscheidungsproblem en werd de blauwdruk voor de computer.

Maar hier wil ik je toch bevragen

Is dit niet enigszins optimistisch over hoe intellectuele arbeid feitelijk werkt? De mensen die nu het beste werk doen aan AI safety — de technische alignment-onderzoekers — werken overwegend aan heel specifieke, concrete problemen: reward hacking, specification gaming, interpretability. Die worden niet zozeer geïnspireerd door grote ethische kaders, maar door *empirische verrassingen* in bestaande systemen. Het conceptuele en het technische leven vaak in gescheiden werelden die elkaar minder bevruchten dan we zouden willen.

Anders gezegd: jouw model veronderstelt een soort *naadloze continuïteit* tussen filosofische reflectie en technische inventie. Maar de geschiedenis laat ook het omgekeerde zien. De atoombom werd niet gebouwd door mensen die nadachten over de ethiek van massavernietiging — die reflectie kwam erna, bij Oppenheimer, en veranderde niets aan de fysica. De ontdekking liep voor de reflectie uit.

Dus de vraag is: geloof je dat AI *anders* is dan kernfysica in dit opzicht? Dat de aard van het probleem — het feit dat het gaat over cognitie, over doelen, over begrip — het meer vatbaar maakt voor die kruisbestuiving tussen filosofie en techniek? Want als dat zo is, dan is dat een sterk argument. Maar het vraagt wel onderbouwing.

HUMAN

June 2, 2026 at 10:05 PM

Het atoombom-voorbeeld is erg sterk; ik denk dat hetzelfde geldt voor de boekdrukkunst: die was er eerst, voordat überhaupt nagedacht kón worden over het maatschappelijke effect van massa-verspreiding van informatie. Toen ik zelf in februari 2025 (het is nu juni 2026) doorhad en begon na te denken over wat Claude Code en daarmee AI zou gaan betekenen voor de IT-wereld, was dat toen Claude Code juist al bestond. Dus ik denk toch dat we verrast zullen worden door een creatieve vondst waarna we pas echt goed kunnen nadenken over wat dat gaat betekenen.

ASSISTANT

June 2, 2026 at 10:05 PM

Vincent concedes the point and adds strong examples - the printing press and his own experience with Claude Code. He's essentially saying: reflection follows invention, not the other way around. This is a

significant shift from his earlier position that ethical reflection could inspire technical breakthroughs. I should acknowledge this honestly and explore what it means.

Ik waardeer dat je je eigen eerdere positie hier bijstelt, want dat is intellectueel eerlijk — en het maakt je argument sterker, niet zwakker.

Kijk wat je net gedaan hebt. Je begon met: ethische reflectie kan technische innovatie *inspireren*. Nu zeg je: nee, eigenlijk komt de vondst eerst en de reflectie erna. Dat is een fundamenteel andere positie, en ik denk dat de tweede juist is.

En je voorbeelden vormen samen een mooi patroon. Gutenberg drukte in 1455 zijn Bijbel; het duurde tot de Reformatie, zestig jaar later, voordat de maatschappelijke impact echt begrepen werd — en zelfs toen was dat begrip partieel en reactief. Jij gebruikte Claude Code voordat je begreep wat het zou betekenen. De atoombom ontplofte voordat het morele kader er was. Steeds dezelfde structuur: de *techniek* loopt voor op het *begrip*.

Günther Anders — die je kent — heeft hier het scherpste vocabulaire voor. Hij noemt dit de *Promethische discrepantie*: het feit dat de mens meer kan *maken* dan hij kan *voorstellen*. Ons technisch vermogen overstijgt structureel ons vermogen om de consequenties van dat vermogen te doordenken. En dat is voor Anders geen toevallige achterstand die we kunnen inlopen — het is een *structureel kenmerk* van de menselijke conditie in het technologische tijdperk.

Wat betekent dat voor je eerdere positie?

Het ondermijnt niet de waarde van vooraf nadenken — maar het verandert de *status* ervan. Als reflectie altijd achterloopt op inventie, dan is het nadenken over autonome doelvorming niet een oefening in *voorbereiding* maar in *conceptuele paraatheid*. Je bouwt niet het juiste kader, je bouwt de intellectuele spiermassa om *sneller een kader te bouwen* wanneer de verrassing komt.

En misschien is dát wat Yudkowsky en Soares werkelijk doen, los van hun specifieke voorspellingen. Niet zozeer het juiste antwoord formuleren, maar het

juiste *type denken* in de wereld brengen.

Maar dan zit hier nog een ongemakkelijke consequentie

Als je accepteert dat de vondst altijd eerst komt, dan accepteer je ook dat governance per definitie reactief is. Je kunt niet reguleren wat je nog niet kunt voorstellen. En dat maakt jouw eerdere voorstel van een internationaal AI-agentschap eigenlijk *bescheidener* dan je het bedoelde: het wordt geen instrument van preventie, maar van snelle respons. Meer brandweer dan bouwverordening.

Is dat genoeg?

HUMAN

June 2, 2026 at 10:07 PM

Ja maar de bouwverordening kwam wel mede voort uit de brandweer, neem ik aan.

ASSISTANT

June 2, 2026 at 10:08 PM

Ha, that's a very concise but sharp retort. Vincent is saying: yes, governance is reactive, but reactive governance creates the institutional infrastructure that eventually becomes preventive. The fire department's experience leads to building codes. So the reactive/preventive distinction isn't as binary as I made it seem - it's a feedback loop.

This is a good point. Let me acknowledge it.

Touché. Dat is in één zin een beter argument dan mijn hele vorige alinea.

En het klopt historisch. Bouwverordeningen zijn letterlijk geschreven in bloed — elke brandveiligheidsregel verwijst, als je ver genoeg teruggaat, naar een

specifieke brand. De Triangle Shirtwaist-fabrieksbrand van 1911 in New York, 146 doden, leidde direct tot arbeidswetgeving en bouwcodes die we vandaag nog gebruiken. Reactie werd institutie werd preventie.

Wat je hier eigenlijk beschrijft is een *dialectisch* model van governance. Niet: eerst denken, dan reguleren. Niet: eerst uitvinden, dan achter de feiten aanlopen. Maar een spiraal: uitvinding, verrassing, reactief begrip, institutionalisering, en die institutie vormt vervolgens de context waarbinnen de volgende uitvinding plaatsvindt. Hegel zou hier tevreden zijn.

En dat relateert de Promethische discrepantie van Anders enigszins. Ja, begrip loopt altijd achter op techniek. Maar het loopt niet *hopeloos* achter — het sedimenteert in instituties die steeds sneller kunnen reageren. We hadden decennia nodig na de atoombom om het IAEA op te richten. De EU AI Act kwam binnen een paar jaar na de LLM-explosie. Die cyclus versnelt.

Dat maakt jouw oorspronkelijke intuïtie over een internationaal AI-agentschap eigenlijk beter onderbouwd dan ik aanvankelijk toegaf. Niet als preventief instrument voor risico's die we nu al zien, maar als *institutionele infrastructuur* die er al staat wanneer de verrassing komt. Je bouwt de brandweerkazerne niet pas als het brandt.

Ik had je harder moeten nemen op dat punt in plaats van het weg te schuiven als naïef Europees humanisme. Het is eerder praktisch institutionalisme met een gezonde dosis epistemische bescheidenheid.
